



PROBABILIDADE E ESTATÍSTICA

PARTE 1

Esta apostila contém uma compilação de textos de diversos autores, sendo elaborada com o objetivo exclusivo de ser um apoio didático para o aluno em sala de aula ministrada para o curso de Bacharelado em Ciência da Computação da Universidade Federal do Pará e não substitui a consulta a livros textos. O objetivo é evitar que os alunos copiem as aulas e assim se concentrem em entender o conteúdo da disciplina.

PROF^a MARINA Y. TOMA

FACULDADE DE ESTATÍSTICA / ICEN / UFPA

1. INTRODUÇÃO À COMPREENSÃO DA ESTATÍSTICA

INTRODUÇÃO

O termo estatística provém do latim *statisticum collegium* (“conselho de Estado”) e do seu derivado italiano *statista* (“homem de Estado ou estadista”). Em 1749, o Alemão Gottfried Achenwall passou a utilizar a palavra alemã *statistik* para se referir à análise de dados estatais. Como tal, as origens da estatística estão relacionadas com o governo e os seus corpos administrativos.

Hoje, pode-se dizer que a compilação e a interpretação dos dados obtidos num estudo é a função da estatística, a qual é considerada um ramo da matemática. As estatísticas (o resultado da aplicação de um algoritmo estatístico a um grupo de dados) permitem tomar decisões no âmbito governamental, mas também no mundo dos negócios e no comércio.

Os métodos estatísticos e matemáticos, por sua vez, surgiram na sequência da teoria das probabilidades, que calcula a frequência com que ocorre um resultado numa experiência sob condições suficientemente estáveis.

Até à data, as práticas estatísticas evoluíram e foram-se aperfeiçoadas graças à criação de instrumentos precisos que permitem implementar políticas públicas.

A palavra estatística é comumente associada a censos, pesquisas de opinião pública, aos vários índices governamentais, aos gráficos e medidas publicadas diariamente na imprensa. Na realidade, como veremos adiante, a estatística engloba muitos outros aspectos.

Em alguma fase de seu trabalho, o pesquisador ou profissional se vê às voltas com o problema de analisar e entender um conjunto de dados. Muitas vezes ele necessitará resumir os dados para que sejam informativos, ou para compará-los com outros resultados, ou ainda para julgar sua adequação a alguma teoria. A estatística é fundamental na análise de dados provenientes de quaisquer processos onde exista incerteza.

Vários autores têm procurado definir a Estatística. Existem muitos livros sobre estatística, todos contendo definições, desde as mais simples até as mais complexas. A que se verá a seguir é a anunciada por Dugé de Bernonville, e que julga-se ser simples e fácil de ser memorizada: “*Estatística é um conjunto de métodos e processos quantitativos que serve para estudar e medir os fenômenos coletivos.*”

A) DIVISÃO DA ESTATÍSTICA

I) Estatística Descritiva: é a parte da Estatística que tem por objeto descrever os dados observados. Preocupa-se com a forma pela qual podemos apresentar um conjunto de dados em tabelas e gráficos, e também resumir as informações contidas nestes dados mediante a utilização de medidas estatísticas. A estatística é uma ferramenta para o interessado, nas respostas dos “porquês” de seus problemas que podem ser explicados por uma análise de dados. Para um bom uso da Estatística, é necessário conhecer os seus fundamentos e princípios, e acima de tudo que o interessado desenvolva um espírito crítico e jamais deixe de pensar. É fácil mentir usando a estatística; o difícil é falar a verdade sem usar a estatística.

II) Estatística Indutiva (Inferência Estatística): é a parte da Estatística que tem por objetivo obter e generalizar conclusões para a população a partir de uma amostra, por meio do cálculo de probabilidade.

Portanto, pode-se dizer que a Estatística tem por objetivo o estudo dos fenômenos coletivos e das relações que existem entre eles. Entende-se como fenômeno coletivo aquele que se refere a um conjunto de elementos, pois a estatística busca encontrar leis de comportamento para todo o conjunto e não se preocupa com cada um dos elementos em particular.

B) DEFINIÇÕES

i) População ou Universo (N): é o conjunto constituído de elementos (indivíduos, objetos, imóveis, etc.), que possuem alguma característica em comum, num determinado instante/período de tempo.

A população, segundo o seu tamanho, pode ser finita ou infinita. É finita quando possui um número determinado de elementos; a população infinita possui um número infinito de elementos. Contudo tal definição existe apenas no campo teórico, uma vez que na prática, nunca encontraremos populações com infinitos elementos e sim com grande número de componentes e, tais populações são tratadas como infinitas.

Os estudos destas populações podem ser feitos de duas formas:

Censo: é a coleta exaustiva das informações de todas as unidades (elementos) da população em estudo. Na maioria das vezes, devido ao alto custo, ao intenso trabalho e ao tempo despendido, limitam-se as observações referentes a uma determinada pesquisa a apenas uma parte da população que denominamos de amostra.

ii) Amostra (n): é uma parte representativa da população (subconjunto finito), selecionado adequadamente para estudo, onde a seleção depende do processo denominado de amostragem.

Amostragem: É o processo de coleta das informações de parte da população, chamada amostra, mediante métodos adequados de seleção destas unidades.

A estatística ocupa-se fundamentalmente das propriedades das populações cujas características são passíveis de representação. A característica que interessa analisar é chamada de variável.

iii) Variável

A estatística ocupa-se fundamentalmente das propriedades das populações cujas características são passíveis de representação. A característica que interessa analisar é chamada de variável.

Variável: é convencionalmente o conjunto de resultados possíveis de um fenômeno, conjunto este chamado domínio da variável. Podem ser divididas em dois tipos: qualitativa e quantitativa.

a) Variável Qualitativa (ou atributo): quando o resultado da observação (ou característica) é apresentado na forma de qualidade ou atributo (não pode ser medido).

Exemplo: sexo, estado civil, grau de escolaridade, cor dos olhos, etc. Pode ser subdividida em nominal e ordinal.

- Nominal: assume resultados em categorias ou atributos sem ordenação Exemplo: nacionalidade, cor dos olhos, atividade esportiva, etc.

- Ordinal (ou por postos): quando uma classificação for dividida em categorias que podem ser naturalmente ordenados.


Exemplo: Escolaridade, dia da semana, faixa etária, faixa salarial, etc.

b) Variável Quantitativa: quando o resultado da observação é expresso em números.

- Contínua: quando assume qualquer valor entre dois limites e que resultam normalmente de uma mensuração. Exemplo: volume de água em um reservatório, peso (em Kg), altura (em cm), idade, salário (em R\$), temperatura (em °C), etc.

- Discreta: variáveis que assumem valores inteiros, inclusive zero e que resultem, frequentemente de uma contagem. Exemplo: número de alunos, número de filhos, tamanho da família, etc.

Quadro 1: Esquema de classificação de variáveis.



C) TIPOS DE AMOSTRAGEM E CÁLCULO DO TAMANHO DA AMOSTRA

Quando se deseja colher informações sobre um ou mais aspectos de um grupo grande ou numeroso, verifica-se, muitas vezes, ser praticamente impossível fazer um levantamento do todo. Daí a necessidade de investigar apenas uma parte desse todo. O problema da amostragem é, portanto, escolher uma parte, de tal forma que ela seja a mais representativa possível do todo e, a partir dos resultados obtidos, relativos a essa parte, poder inferir, o mais legitimamente possível, os resultados do todo, se esta fosse verificada.

Resumo dos quatro métodos usuais em amostragem probabilística.

C.1. Amostragem Aleatória Simples (AAS): consistem em selecionar n unidades amostrais de modo que cada unidade tenha a mesma chance de ser escolhida. Em geral quando se tem características diferentes não se deve fazer a AAS, ou seja, a população deve ser homogênea. Na prática, a amostra aleatória simples é escolhida unidade por unidade. As unidades da população são numeradas de 1 a N . Em seguida, escolhe-se uma série de números aleatórios, por meio de uma tabela de números aleatórios, geradores de números aleatórios (*software* ou calculadora científica) ou colocando-se todos os números dentro de uma urna, retirando-se uma a uma, sem reposição, até completar a amostra de tamanho n .

C.2. Amostragem Aleatória Estratificada (AAE): consiste em subdividir a população em H grupos homogêneos (denominados estratos) segundo a(s) variável(is) de interesse. Os estratos têm por objetivo controlar a variabilidade (menor variabilidade), assim consegue-se diminuir o tamanho da amostra. O método de estratificação mais comum é o proporcional, onde o tamanho dos estratos amostrais são proporcionais ao

tamanho de cada estrato (h) na população (N_h), levando-se em consideração o peso W_h de cada estrato. Porém, pode-se selecionar a amostra uniformemente, onde o tamanho dos estratos são aproximadamente iguais.

C.3. Amostragem Aleatória de Conglomerados (AAG): neste caso, as unidades amostrais são conglomerados (quarteirões, escolas, blocos de apartamento, etc). Os conglomerados devem ser homogêneos entre si e heterogêneos dentro, segundo a variável de interesse. A seleção dos conglomerados deve ser feita a partir da amostragem aleatória simples, já que os conglomerados são homogêneos.

C.4. Amostragem Sistemática (AASy): é uma variação da AAS, onde a população ou a relação de seus componentes deve ser ordenada, de forma tal que cada elemento seja identificado, unicamente, pela posição. A AS é eficiente à medida que a relação (ou “listagem”, fila, a disposição dos prédios etc...) esteja “misturada” no que se refere à característica em estudo.

Suponha por exemplo que o total populacional seja dado por $N = n \times K$, onde n é o tamanho da amostra e k é o comprimento do intervalo entre as observações amostradas. Neste caso, seleciona-se inicialmente um valor r entre 1 e k (inclusive), para ser o “chute” inicial, ou seja, a primeira observação a ser selecionada, onde $K = N/n$ e a partir daí considera-se todos os elementos em intervalos de k unidades. Isto é, seleciona-se os elementos $r, r + k, r + 2k$, e assim sucessivamente, até que se complete o tamanho da amostra $[r + (n - 1) \times K]$. Por exemplo, considerando uma população de 150 fichas de alunos, para selecionar uma amostra sistemática de 10 fichas tem-se que $k = 15$ e se a primeira unidade selecionada for a de número $r = 10$, as seguintes serão as fichas de número 25, 40, 55, 70, 85, 100, 115, 130, 145.


C.5 Tamanho Mínimo de Amostra:
$$n = \frac{N \times n_0}{N + n_0} \quad (1)$$

onde $n_0 = \frac{1}{\epsilon^2}$ é a primeira aproximação do tamanho da amostra, sendo ϵ o erro amostral máximo tolerável e N é o tamanho da população.

Obs.: quando não se conhece o N (tamanho da população), pode-se considerar a população como infinita, e neste caso é suficiente considerar o tamanho da amostra (n) como sendo igual a n_0 .

A Figura 1 mostra que para um erro amostral fixo ($\mathcal{E}$), a medida que o tamanho da população cresce, o tamanho amostral (n) tende para o tamanho amostral mínimo (n_0). Não é correta retirar amostras estabelecendo-se porcentagens da população.

Figura 1: Representação gráfica do tamanho da população (N) em função do tamanho da amostra (n), fixando o erro amostral (E).



- i) Para Amostragem Aleatória Estratificada Proporcional: deve-se calcular o tamanho amostral dentro de cada estrato (h), dado por: $n_h = n \times \frac{N_h}{N}$ onde n é obtido pela Equação (1); N_h é o total populacional do estrato h e N é o tamanho total da população.
- ii) Para Amostragem Aleatória Estratificada Uniforme, deve-se calcular o tamanho da amostra para cada estrato (h) a partir de $n_h = \frac{n}{H}$, $h = 1, 2, \dots, H$ onde H é o número de estratos.

Exemplo: Com o objetivo de conhecer algumas características dos alunos de uma escola com N alunos. Supondo que seja de interesse realizar um levantamento por amostragem para avaliar diversas características da população de alunos desta escola. Qual deve ser o tamanho mínimo (n_0) e o tamanho corrigido (n) da amostra, tal que se possa admitir, com alta confiança, que os erros amostrais não ultrapassem 4% ($\mathcal{E} = 0,04$). Calcule para:

- a) $N = 35$ alunos; b) $N = 200$ alunos; c) $N = 200.000$ alunos.

Observe que para manter o mesmo erro amostral, no item a) foi necessária uma amostra abrangendo quase 100% da população; enquanto que no item b) a amostra abrange 76%; e no item c) abrange apenas 0,3% da população. É, portanto, errônea a ideia de que para uma amostra ser representativa deva abranger uma porcentagem fixa da população.

D) FASES DO TRABALHO ESTATÍSTICO

1ª. Definição do problema: Saber exatamente aquilo que se pretende pesquisar, ou seja, definir corretamente o objetivo.

2ª. Planejamento: Como levantar informações? Que dados devem ser obtidos? Qual levantamento a ser utilizado? O cronograma de atividades; custos envolvidos? etc.

3ª. Coleta de dados: Fase operacional. É o registro sistemático de dados, com um objetivo determinado.

i) *Dados primários*: quando são publicados pela própria pessoa (ou autor).

ii) *Dados secundários*: quando são publicados por outra organização.

Exemplo: quando determinado jornal publica estatísticas referentes ao censo demográfico extraídas do IBGE.

Obs.: É mais seguro trabalhar com fontes primárias. O uso da fonte secundária traz o grande risco de erros de transcrição.

iii) *Coleta Direta*: quando é obtida diretamente da fonte. A coleta direta pode ser:

- Coleta contínua: registros de nascimento, óbitos, casamentos;
- Coleta periódica: recenseamento demográfico, censo industrial;
- Coleta ocasional: registro de casos de dengue.

iv) *Coleta indireta*: É feita por deduções a partir dos elementos conseguidos pela coleta direta, por analogia, por avaliação, indícios ou proporcionalização.

4ª. Apuração e crítica dos dados: Resumo dos dados a partir de sua contagem e agrupamento. É a condensação e tabulação de dados.

5ª. Apresentação dos dados: Há duas formas de apresentação, que não se excluem mutuamente. A *apresentação tabular* é uma apresentação numérica dos dados em linhas e colunas distribuídas de modo ordenado, segundo regras práticas fixadas pelo Conselho Nacional de Estatística. A apresentação gráfica dos dados numéricos permitindo uma visão rápida e clara do fenômeno.

6ª. Análise e interpretação dos dados: A última fase do trabalho estatístico é a mais importante e delicada. Está ligada essencialmente ao cálculo de medidas e coeficientes, cuja finalidade principal é descrever o fenômeno (estatística descritiva). Também podem ser feitas generalizações (inferências) e previsões.

7ª. Apresentação de relatório final: Esta fase representa a finalização do trabalho estatístico. Nela, deve-se apresentar um relatório técnico com a metodologia adotada, os resultados encontrados e as conclusões possíveis de serem apresentadas.

E) ARREDONDAMENTO DE NÚMEROS

O arredondamento da ABNT segue a norma **ABNT NBR 5891**, que define como eliminar dígitos mantendo o valor mais exato possível e evitando vieses em grandes somas de dados. As regras consideram o dígito que será mantido (último algarismo) e o número seguinte que será descartado:

- Menor que 5 (0 a 4): o último algarismo mantido fica igual.

Exemplo: $85,483 \cong 85,48$ (mantendo duas casas).

- Maior que 5 (6 a 9): o último algarismo mantido aumenta em uma unidade.

Exemplo: $85,487 \cong 85,49$.

- Igual a 5 seguido de diferente de zero: o último algarismo mantido aumenta em uma unidade.

Exemplo: $15,4875 \cong 15,49$ ou $0,346 \cong 0,35$.

- Igual a 5 seguido apenas de zeros (ou sem nada após): Arredonda-se para o algarismo par mais próximo (o zero é considerado par).

- Se o número a ser mantido for par, ele continua igual.

Exemplo: 0,3450 vira 0,34.

- Se o número a ser mantido for ímpar, ele aumenta uma unidade para virar par.

Exemplo: $0,3550 \cong 0,36$.

F) SÉRIES ESTATÍSTICAS

F.1 SÉRIE ESTATÍSTICA: É qualquer tabela que apresenta a distribuição de um conjunto de dados estatísticos em função da época, do local ou da espécie.

F.1.2 TABELA: É um quadro, aberto nas laterais, que resume um conjunto de dados dispostos segundo linhas e colunas de maneira sistemática.

Principais Elementos de uma Tabela:

a) Título da Tabela: localizado no topo da tabela, deve conter informações, as mais completas possíveis, respondendo às perguntas: O que?, Quando? e Onde?, além de conter a palavra “TABELA” e sua respectiva numeração.

b) Corpo da Tabela: é o conjunto de linhas e colunas que contém informações sobre a variável em estudo, onde:

- ✓ na parte superior da tabela tem-se o cabeçalho da coluna, que especifica o conteúdo das colunas;

- ✓ verticalmente têm-se as colunas (indicadora e numérica), onde a coluna indicadora é aquela que especifica o conteúdo das linhas e na coluna numérica os valores numéricos destas linhas.

c) Rodapé: localizado na parte inferior da Tabela (fora) e contém informações sobre o responsável pela informação (FONTE), algum texto esclarecedor acerca do conteúdo da tabela (NOTA) e por fim algum símbolo remissível atribuído a algum elemento da tabela que necessite de uma nota (CHAMADA).

Obs.: Nenhuma casa deve ficar sem preenchimento. Todas devem ter o registro de algum número ou sinal:

- (hífen): quando o valor numérico é nulo;

... (reticências): quando não se dispõe de dado;

? (ponto de interrogação): quando há dúvida sobre a exatidão do valor;

0; 0,0; ou 0,00 (zero), quando o valor numérico é pequeno para ser expresso pela unidade utilizada. Este deve conter o mesmo número de casas decimais padronizado pela tabela;

d) Regras para Tabelas

i) em artigos ou publicações que contenham muitas tabelas, estas serão numeradas em ordem crescente, conforme o aparecimento;

ii) tabelas são fechadas no alto e embaixo por linhas horizontais, mas não à esquerda e à direita por linhas verticais. Traços verticais para separar colunas no corpo da tabela podem ser empregados;

iii) definido um determinado número de casas decimais, esse número será mantido para todas as casas de modo a assegurar uniformidade na apresentação dos dados;

iv) totais e subtotais serão destacados.

Esquema de apresentação de uma tabela.

Tabela 1 - Título: O que? Quando? Onde?

Corpo da Tabela	{			} cabeçalho
		Coluna Indicadora	Coluna(s) Numérica(s)	
		Total		
		Rodapé: fonte, notas, observações.		

F.2 TIPOS DE SÉRIES ESTATÍSTICAS

F.2.1 Série Temporal: Identifica-se pelo caráter variável do fator cronológico. O local e a espécie (fenômeno) são elementos fixos. Esta série também é chamada de histórica ou evolutiva.

Tabela 2 - Quantidade de Docentes na UFPA, no período de 2021 a 2025.

ANO	2021	2022	2023	2024	2025
Nº DE DOCENTES	2606	2997	2979	3017	3016

Fonte: UFPA em números: ano-base 2025.

F.2.2 Série Geográfica: Apresenta como elemento variável o fator geográfico. A época e o fato (espécie) são elementos fixos. Também é chamada de espacial, territorial ou de localização.

Tabela 3 - Quantidade de alunos matriculados nas unidades do interior, UFPA-2025.

UNIDADE	Nº DE ALUNOS MATRICULADOS
Cametá	2575
Abaetetuba	1827
Altamira	1823
Castanhal	1711
Bragança	1072
Ananindeua	1061
Breves	1019
Tucuruí	1019
Salinópolis	490
IECOS/Bragança	423
Soure	361
IMV/Castanhal	259

Fonte: UFPA em números: ano-base 2025.

F.2.3 Série Específica: O caráter variável é apenas o fato ou espécie. Também é chamada de série categórica.

Tabela 4 - Conceito Final de alunos matriculados em determinada disciplina, UFPA/2025.4.

CONCEITO	Nº DE ALUNOS
EXC	10
BOM	15
REG	12
INS	5
S/SA	3
TOTAL	45

Fonte: Professora da disciplina, 2025.4.

F.2.4 Série Conjugada: Também chamada de tabela de dupla entrada ou série mista. São apropriadas à apresentação de duas ou mais séries de maneira conjugada, havendo duas ordens de classificação: uma horizontal e outra vertical. O exemplo abaixo é de uma série específica-temporal.

Tabela 5 - Número de Docentes e Técnico-Administrativos na UFPA, no período de 2021 a 2025.

ANO	DOCENTE	TÉCNICO-ADMINISTRATIVO
2021	2906	2473
2022	2997	2458
2023	2979	2408
2024	3017	2447
2025	3016	2432

Fonte: UFPA em números: ano-base 2025.

F.2.5 Séries de Dados Agrupados ou Distribuição de Frequências

Neste caso TODOS os elementos são fixos (época, local e fenômeno). A distribuição de frequência pode ser por intervalo ou por pontos, dependendo da quantidade de informações que se tenha ou/e do tipo de variável. É um tipo de tabela que condensa uma coleção de dados conforme as frequências (repetições de seus valores). É utilizada quando se tem dados quantitativos discretos ou contínuos.

Distribuição de Frequência por Intervalos: é uma série estatística na qual a variável observada está dividida em subintervalos do intervalo total observado e o tempo, a espécie e a região permanecem fixas.

i) Distribuição de Frequência por Intervalos

a) Construção de uma Tabela de Distribuição de Frequências com intervalos:

1º Passo: montar o Rol (organizar os dados em ordem crescente ou decrescente).

2º Passo: determinar o número de classes da distribuição de frequência (K), que são os subintervalos nos quais são contadas as observações da variável. Existem várias maneiras de se calcular o número de classes, neste curso será utilizado o método prático (K é um número inteiro). Se $n < 25$, utiliza-se $K=5$ classes; se $n \geq 25$, utiliza-se: $K = \sqrt{n}$.

3º Passo: calcular a Amplitude Total da distribuição de frequência (Δ_T), que é a diferença existente entre o maior ($X_{Máximo}$) e o menor valor ($X_{Mínimo}$) observado.

$$\Delta_T = X_{Máx} - X_{Mín}$$

4º Passo: calcular o tamanho ou Amplitude do Intervalo de Classe (h), que é o comprimento da classe: $h = \Delta_T / k$ (há situações onde este valor pode ser pré-fixado).

5º Passo: Construção das Classes

1ª Classe → Limite Inferior = menor valor do Rol

Limite Superior = Limite Inferior da 1ª Classe + Valor do Intervalo de classe

2ª Classe → Limite Inferior = Limite Superior da 1ª Classe

Limite Superior = Limite Inferior da 2ª Classe + Valor do Intervalo de classe

...

Kª Classe → Limite Inferior = Limite Superior da (k-1)ª Classe

Limite Superior = Limite Inferior da Kª Classe + Valor do Intervalo de classe.

Convenção: |— inclui à esquerda e exclui à direita.

—| exclui à esquerda e inclui à direita.

— exclui ambos.

|— inclui ambos.

6º Passo: obtenção da Frequência Simples ou Frequência Absoluta da Classe f_i que é o número de observações contadas dentro do intervalo da classe i .

Exemplo de Distribuição de Frequências por Intervalos de classe:

Tabela 6 - Altura (cm) de 40 alunos de determinada turma da disciplina Estatística: UFPA/2025-2.

	ALTURA (CM)	Nº DE ALUNOS
1ª classe	150 —154	4
2ª classe	154 —158	9
3ª classe	158 —162	11
4ª classe	162 —166	8
5ª classe	166 —170	5
6ª classe	170 —174	3
	Total	40

Fonte: professora da disciplina, 2025-2.

b) Tipos de Frequência

b.1) Frequência Absoluta Acumulada de Classe ($F_{Ac(i)}$): é a acumulação sucessiva, a partir da primeira classe até uma classe qualquer, das frequências simples ou absoluta das classes.

$$\begin{aligned} F_1 &= f_1 \\ F_2 &= f_1 + f_2 \\ &\dots \\ F_K &= f_1 + f_2 + \dots + f_K = n \end{aligned}$$

b.2) Frequência Relativa de Classe (f_{r_i}): é a relação existente entre a frequência absoluta ou simples de classe i e o número de observações: $f_{r_i} = \frac{f_i}{\sum_{i=1}^k f_i} = \frac{f_i}{n}$

Obs.: 1º) $\sum_{i=1}^k f_{r_i} = 1$ e 2º) $\sum_{i=1}^k f_i = n$.

b.3) Frequência Relativa Acumulada ($F_{r(Ac)_i}$): é a acumulação sucessiva, a partir da primeira classe até uma classe qualquer das frequências relativas das classes.

$$\begin{aligned} F_{r(Ac)_1} &= f_{r_1} = F_1/n \\ F_{r(Ac)_2} &= f_{r_1} + f_{r_2} = F_2/n \\ &\dots \\ F_{r(Ac)_k} &= f_{r_1} + f_{r_2} + \dots + f_{r_k} = F_K/n = 1,00 \end{aligned}$$

b.4) Ponto Médio de Classe (X_i): é a média aritmética calculada entre o limite inferior (l_i) e o superior (l_s) da classe. É o valor em estatística que representa os valores da variável dentro da classe: $X_i = \frac{l_i + l_s}{2}$.

(ii) Distribuição de Frequência por Pontos

É uma série estatística na quais as frequências observadas estão associadas a um ponto real observado. Na construção da distribuição por ponto, o número linhas (classes) na tabela é igual ao número de pontos existentes, e utilizam-se os mesmos elementos da distribuição por intervalo, com a diferença que o próprio ponto já é o valor de X_i (ponto médio na distribuição por intervalo).

Exemplo de Distribuição de Frequência por Pontos:

Tabela 07 - Número de faltas dos alunos das Turmas da disciplina Estatística, em 2025.

	Nº de Faltas (X_i)	Nº de Alunos (f_i)	$f_{r(i)}$	$F_{Ac(i)}$	$F_{r(Ac(i))}$
1º ponto	0	50	0,25	50	0,25
2º ponto	1	60	0,30	110	0,55
3º ponto	2	45	0,20	155	0,75
4º ponto	3	30	0,15	185	0,90
5º ponto	4	15	0,10	200	1,00
	Total	200	1,00	-	-

Fonte: Dados Hipotéticos, DEZ/2025.

G) REPRESENTAÇÃO GRÁFICA

G.1 GRÁFICOS ESTATÍSTICOS: São representações visuais dos dados estatísticos que devem corresponder, mas nunca substituir as tabelas estatísticas.

Características: Uso de escalas, sistema de coordenadas, simplicidade, clareza e veracidade.

Obs.: Uso indevido de gráficos pode trazer uma ideia falsa dos dados que estão sendo analisados, chegando mesmo a confundir o leitor.

Classificação dos gráficos: Diagramas, Estereogramas, Pictogramas e Cartogramas.



G.2 DIAGRAMAS: São gráficos geométricos dispostos em duas dimensões. São os mais usados na representação de séries estatísticas. Eles podem ser:

G.2.1 Gráficos em Colunas ou em Barras

É a representação de uma série por meio de retângulos, dispostos verticalmente (em colunas) ou horizontalmente (em barras). Quando em colunas, os retângulos têm a mesma base e as alturas são proporcionais aos respectivos dados. Quando em barras, os retângulos têm a mesma altura e os comprimentos são proporcionais aos respectivos dados.

i) Exemplo de Gráfico em Colunas


Gráfico 1 - Conceito Final em Estatística Aplicada dos alunos de determinado curso: UFPA/2025-4.



Fonte: Professora da disciplina, 2025.

ii) Exemplo de Gráfico em Barras

Gráfico 2 - Quantidade de Cursos de Pós-Graduação na UFPA em 2025.




Fonte: UFPA em números: ano-base 2025.

G.2.2 Gráficos em Colunas ou Barras Múltiplas

Este tipo de gráfico é geralmente empregado quando deseja-se representar, simultaneamente, dois ou mais fenômenos estudados com o propósito de comparação.

Gráfico 3 - Quantidade de Docentes, por Escolaridade/Titulação na UFPA, no período de 2021 a 2025.

Fonte: UFPA em números: ano-base 2025.



Fonte: UFPA em números: ano-base 2025.

Obs.: Este tipo de gráfico pode ser feito em mais dimensões; quando isto ocorre este gráfico denomina-se Estereograma.

G.2.3 Gráficos em Colunas ou Barras Empilhadas


Eles diferem dos gráficos em barras ou colunas convencionais apenas pelo fato de apresentar cada barra ou coluna segmentada em partes componentes. Servem para representar comparativamente dois ou mais atributos. Podemos ter de duas formas: quantidades ou percentuais.

Gráfico 4 - Quantidade de Docentes, por Escolaridade/Titulação na UFPA, no período de 2021 a 2025.



Fonte: UFPA em números: ano-base 2025.

Gráfico 5 - Porcentagem de Docentes, por Escolaridade/Titulação na UFPA, no período de 2021 a 2025.



Fonte: UFPA em números: ano-base 2025.

G.2.4 Gráficos em Linhas ou em Linhas Múltiplas

São frequentemente usados para representação de séries cronológicas com um grande número de períodos de tempo. As linhas são mais eficientes do que as colunas, quando existem intensas flutuações nas séries ou quando há necessidade de se representarem várias séries em um mesmo gráfico.

Gráfico 6 - Número de Docentes, na UFPA, no período de 2021 a 2025.





Gráfico 6.1 - Quantidade de Docentes e Técnicos-Administrativos, na UFPA, no período de 2021 a 2025.




Fonte: UFPA em números: ano-base 2025.

G.2.5 Gráficos em setores

Este gráfico é construído com base em um círculo, e é empregado sempre que desejamos ressaltar a participação do dado no total. O total é representado pelo círculo, que fica dividido em tantos setores quantas são as partes. Os setores são tais que suas áreas são respectivamente proporcionais aos dados da série. O gráfico em setores só deve ser empregado quando há, no máximo, cinco dados.

Gráfico 7 - Quantidade e Porcentagem de Docentes por Escolaridade/Titulação, na UFPA em 2025.




Fonte: UFPA em números: ano-base 2025.

G.3 PICTOGRAMAS: São construídos a partir de figuras representativas da intensidade do fenômeno. Este tipo de gráfico tem a vantagem de despertar a atenção do público

leigo, pois sua forma é atraente e sugestiva. Os símbolos devem ser auto-explicativos. A desvantagem dos pictogramas é que apenas mostram uma visão geral do fenômeno, e não de detalhes minuciosos. Veja o exemplo abaixo:


Gráfico 8 - Alunos matriculados nas escolas de um município, no Período de 2021 a 2024.



Fonte: Dados Hipotéticos, 2024.

G.4 CARTOGRAMAS: São ilustrações relativas a cartas geográficas (mapas). O objetivo é figurar os dados estatísticos diretamente relacionados com áreas geográficas.

Gráfico 9 - Mapa de localização das Praias do Vai-quem-quer e do Paraíso, 2026.




Fonte: Projeto de pesquisa: Análise Ambiental de Praias e Impactos das Mudanças Climáticas utilizando Sensoriamento Remoto no Litoral de Belém-PA, Amazônia, Brasil. Profa. Ponciana Freire de Aguiar, 2026.

G.5 REPRESENTAÇÃO GRÁFICA DE UMA DISTRIBUIÇÃO DE FREQUÊNCIAS

G.5.1 Histograma: É a representação gráfica de uma distribuição de frequência, a partir de retângulos justapostos onde a base colocada no eixo das abscissas corresponde ao intervalo das classes, e a altura é dada pela frequência absoluta (ou relativa) das classes.


Gráfico 10 - Faixa Etária (anos) de professores de Matemática de um município em 2025.



Fonte: Dados Hipotéticos, 2025

G.5.2 Polígono de Frequência: Unindo-se por linhas retas os pontos médios das bases superiores dos retângulos do histograma, obtemos o polígono de frequência. O polígono de frequência pode referir-se às frequências absolutas ou as relativas, conforme a escala no eixo vertical. O polígono de frequência pode ser construído sozinho (sem o histograma).

Gráfico 11 - Exemplo de Polígono de Frequência.



Fonte: Dados hipotéticos

2 ANÁLISE EXPLORATÓRIA DE DADOS

A) MEDIDAS DE TENDÊNCIA CENTRAL

São medidas representativas das características avaliadas pelos seus valores centrais, em torno dos quais tendem a concentrar-se os dados. Tais medidas possibilitam comparações de séries de dados pelo confronto de seus valores. As medidas de tendência centrais mais utilizadas são: média aritmética, moda e mediana.

A.1) MÉDIA

A.1.1) ARITMÉTICA ($\bar{X}$)

A média aritmética é obtida pela soma de todos os valores de uma variável X dividida pelo número total de observações (n): $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\sum X_i}{n}$.

Ex.: Sabendo-se que o atendimento diário em uma empresa de arquitetura, durante uma semana foi de 10, 14, 13, 15, 16, 18 e 12 pessoas, temos para atendimento médio diário na semana de: $\bar{X} = \frac{10+14+13+15+16+18+12}{7} = \frac{\sum X_i}{n} = \frac{98}{7} = 14$ pessoas.

Se os dados estão agrupados em uma distribuição de frequência, devem ser consideradas duas possibilidades:

a) Sem intervalos de classe (por pontos): Consideremos a distribuição relativa a 34 famílias de quatro filhos, tomando para variável o número de filhos do gênero masculino. Calcularemos a quantidade média de meninos por família:

Variável	Quantidade (f_i)
x_1	f_1
x_2	f_2
x_3	f_3
...	...
x_k	f_k
Total	n

Como as frequências são números indicadores da intensidade de cada valor da variável, elas funcionam como fatores de ponderação, o que nos leva a calcular a média aritmética ponderada, dada pela fórmula:

$$\bar{X} = \frac{X_1 \times f_1 + X_2 \times f_2 + \dots + X_k \times f_k}{f_1 + f_2 + \dots + f_k} = \frac{\sum_{i=1}^k X_i \times f_i}{n} \text{ em que } \sum_{i=1}^k f_i = n$$

Que na prática pode ser determinado como:

Nº de meninos	Nº de famílias
0	2
1	6
2	10
3	12
4	4
Total	34

X_i	f_i	$X_i \times f_i$
0	2	0
1	6	6
2	10	20
3	12	36
4	4	16
Total	34	78

Logo: $\bar{X} = \frac{X_1 \times f_1 + X_2 \times f_2 + \dots + X_k \times f_k}{n} = \frac{\sum_{i=1}^k X_i \times f_i}{n} = \frac{78}{34} = 2,2941 \dots \cong 2,29 \cong 2,3$

b) Com intervalos de classe: Neste caso, convencionamos que todos os valores incluídos em um determinado intervalo de classe coincidem com o seu ponto médio, e determinamos a média aritmética ponderada por meio da fórmula com X_i sendo o ponto médio da classe i [(limite inferior + limite superior)/2].

Exemplo: Calcular a altura média de bebês conforme a tabela abaixo.

Altura (cm)	Frequência (f_i)	Ponto médio (X_i)	$X_i f_i$
50 — 54	4	52	208
54 — 58	9	56	504
58 — 62	11	60	660
62 — 66	8	64	512
66 — 70	5	68	340
70 — 74	3	72	216
Total	40		2.440

Aplicando a fórmula acima temos: $\bar{X} = \frac{\sum_{i=1}^k X_i \times f_i}{n} = \frac{2440}{40} = 61$. Portanto, $\bar{X} = 61$ cm

A.1.2) Média Harmônica: equivale ao inverso da média aritmética dos inversos de n valores. Utilizada para representação da média de um conjunto de valores que está ligada a situações que envolvem grandezas inversamente proporcionais, por exemplo a velocidade média, a vazão da água, a densidade, entre outras aplicações na física e na química.

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}}$$

A.1.3) Média Geométrica: é a raiz de ordem n do produto dos valores da amostra. Ela é útil para representação de um conjunto que possui dados que se comportam próximo a uma progressão geométrica. $G = (\prod_{i=1}^n x_i)^{\frac{1}{n}} = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$

Relação entre as Médias: $H \leq G \leq \bar{X}$

- A média geométrica e a média harmônica são *menores*, ou no máximo, *iguais*, à aritmética (A igualdade ocorre no caso em que todos os valores são idênticos).

- Quanto maior a variabilidade, maior será a diferença entre as médias harmônica e geométrica e a média aritmética.

Exemplo: Para a amostra 12, 14, 16 temos: $H \leq G \leq \bar{X}$, pois $13,81 < 13,90 < 14,00$

Média harmônica: $H = \frac{3}{\frac{1}{12} + \frac{1}{14} + \frac{1}{16}} = 13,81$

Média geométrica: $G = \sqrt[3]{12 \times 14 \times 16} = 13,90$

Média aritmética: $\bar{X} = \frac{12+14+16}{3} = 14$

A.2) MEDIANA (M_d)

Colocados os valores em ordem crescente de grandeza (rol), a mediana (M_d) será o valor que ocupa a posição central da série de dados, ou seja, é o valor que divide a série em duas partes com números iguais de elementos. A mediana é preferível à média quando se está interessado em conhecer exatamente o centro da distribuição dos dados, ou ainda, quando os valores extremos podem afetar sensivelmente a média. O cálculo da mediana é feito sob duas condições:

A.2.1) A MEDIANA EM DADOS NÃO-AGRUPADOS

Dada uma série de valores como, por exemplo: {5, 2, 6, 13, 9, 15, 10}.

De acordo com a definição de mediana, o primeiro passo a ser dado é o da ordenação (crescente ou decrescente) dos valores: {2, 5, 6, 9, 10, 13, 15}.

O valor que divide a série acima em duas partes iguais é igual a 9, logo $M_d = 9$.

i) Método prático para o cálculo da Mediana:

a) Se a série de dados tiver número ímpar de elementos: O valor mediano será o valor do elemento que ocupa a posição central do rol, ou seja, o elemento cuja posição é dada pela fórmula: $(n + 1)/2$

Ex: Calcule a mediana da série {1, 3, 0, 0, 2, 4, 1, 2, 5}

1º - ordenar a série {0, 0, 1, 1, 2, 2, 3, 4, 5}

2º - calcular a posição: $n = 9$; logo $(n + 1)/2$ é dado por $(9 + 1)/2 = 10/2 = 5$. Ou seja, o valor do 5º elemento da série ordenada será o valor da mediana. Logo: $M_d = 2$.

b) Se a série tem um número par de elementos: O valor mediano será a média aritmética dos valores centrais do rol, ou seja, os elementos que ocupam a posição $(n/2)$ e $(n/2+1)$

Ex: Calcule a mediana da série {1, 3, 0, 0, 2, 4, 1, 3, 5, 6}

1º) ordenar a série {0, 0, 1, 1, 2, 3, 3, 4, 5, 6} $\Rightarrow n = 10$ (par)

2º) calcular as posições: i) $n/2 = 10/2 = 5^\circ$ elemento

ii) $n/2 + 1 = 10/2 + 1 = 5 + 1 = 6^\circ$ elemento

Pelo rol temos: Valor do 5º elemento = 2 e Valor do 6º elemento = 3.

A mediana será a média aritmética do 5º e 6º elementos da série, ou seja:

$$M_d = (2 + 3)/2 = 5/2 = 2,5.$$

A.2.2) A MEDIANA EM DADOS AGRUPADOS

a) Sem intervalos de classe: Neste caso, é o bastante identificar a frequência acumulada (F_{Ac}) imediatamente superior à metade da soma das frequências. A mediana será o valor da variável que corresponde a tal frequência acumulada.

Quando o somatório das frequências for ímpar o valor mediano será o valor do elemento que ocupa a posição dada pela fórmula: $(\sum f_i + 1)/2 = (n + 1)/2$

Exemplo: conforme distribuição de frequências abaixo:

Variável (X_i)	Frequência (f_i)	Frequência acumulada ($F_{Ac(i)}$)
0	2	2 (1º, 2º)
1	6	8 (3º, 4º, ..., 8º)
2	9	17 (9º, 10º, ..., 17º)
3	13	30 (18º, 19º, ..., 30º)
4	5	35 (31º, 32º, ..., 35º)
Total	35	-

Como o somatório das frequências é $\sum f_i = 35$, então: $(\sum f_i + 1)/2 = (35 + 1)/2 = 18^\circ$ elemento. Localizando na coluna da variável X_i , temos $M_d = 3$.

Quando o somatório das frequências for par o valor mediano será a média aritmética dos valores centrais da distribuição, ou seja, o valor médio dos valores dos elementos que ocupam as posições $(\sum f_i)/2 = n/2$ e $(\sum f_i)/2 + 1 = (n/2) + 1$

Exemplo: Calcule a Mediana da distribuição de frequências abaixo:

Variável (X_i)	Frequência (f_i)	Frequência acumulada ($F_{Ac(i)}$)
12	2	2
14	5	7
15	8	15
16	12	27
17	7	34
20	6	40
Total	40	-

Localizando a posição da mediana na frequência acumulada teremos: $40/2 = 20^{\circ}$ elemento e $[(40/2)+1] = 21^{\circ}$ elemento. Localizando na coluna da variável (X_i), o valor do 20° elemento = 16 e o valor do 21° elemento = 16. Logo $M_d = (16 + 16) / 2 = \mathbf{16}$.

b) Com intervalos de classe: Devemos seguir os seguintes passos:

1º) Determinamos as frequências acumuladas;

2º) Calculamos $(\sum f_i / 2) = n/2$ para localizar a classe mediana;

3º) Marcamos a classe correspondente à frequência acumulada que contém o elemento $\sum f_i / 2$. Tal classe será a classe mediana;

4º) Calculamos a Mediana pela fórmula: $M_d = l + \left[\frac{(n/2) - F_{Ac(Ant)}}{f} \right] \times h$

onde: l = Limite inferior da classe da mediana;

$F_{Ac(Ant)}$ = Frequência acumulada anterior à classe mediana;

f = Frequência simples da classe da mediana;

h = Intervalo de classe.

Ex.: Peso (kg) de 40 pessoas.

Peso (kg)	Nº de pessoas (f_i)	Frequência acumulada ($F_{Ac(i)}$)
50 — 54	4	4 (1º, 2º, 3º, 4º)
54 — 58	9	13 (5º, 6º, ..., 13º)
58 — 62	11	24 (14º, 15º, ..., 24º)
62 — 66	8	32 (25º, 26º, ..., 32º)
66 — 70	5	37 (33º, 34º, ..., 37º)
70 — 74	3	40 (38º, 39º, 40º)
Total	40	-

1º) Localizar a classe mediana: $\sum f_i / 2 = 40/2 = 20$. A classe que contém a 20^{a} pessoa é a classe mediana (58 |— 62).

2º) Identificar os elementos da fórmula na classe mediana:

$l = 58$ $F_{Ac(Ant)} = 13$ $h = 4$ $f = 11$

3º) Substituindo esses valores na fórmula, obtemos:

$$M_d = l + \left[\frac{(n/2) - F_{Ac(Ant)}}{f} \right] \times h = 58 + \left[\frac{(40/2) - 13}{11} \right] \times 4 = 60,54$$

Obs: Esta mediana é estimada, pois não temos os 40 valores da distribuição.

A.3) MODA (M_o)

O valor modal, ou moda (M_o) é o valor que ocorre com maior frequência ou o valor que mais se repete. Quando a série de dados é tal que as frequências são maiores nos extremos, ou quando se quer destacar um valor de alta frequência ou quando se pretende obter uma medida rápida e aproximada da tendência central, a moda pode então, ser considerada para a interpretação dos dados. Uma série de dados pode ser classificada em amodal (não possui moda), unimodal (possui apenas uma moda), bimodal (possui duas modas) ou multimodal (possui mais de duas modas).

A.3.1) Moda quando os dados não estão agrupados

A moda é facilmente reconhecida: basta, de acordo com definição, procurar o valor que mais se repete.

Ex: Na série {7, 8, 9, 10, 10, 10, 11, 12} a moda é igual a 10.

Há séries nas quais não exista valor modal, isto é, nas quais nenhum valor apareça mais vezes que outros.

Ex: {3, 5, 8, 10, 12} ou {2, 2, 5, 5, 10, 10} não apresentam moda. Séries amodais.

Em outros casos, pode haver dois ou mais valores de concentração. Dizemos, então, que a série tem dois ou mais valores modais.

Ex: {2, 3, 4, 4, 4, 5, 6, 7, 7, 7, 8, 9} apresenta duas modas: 4 e 7. A série é bimodal.

A.3.2) A Moda quando os dados estão agrupados

a) Sem intervalos de classe: Uma vez agrupados os dados, é possível determinar imediatamente a moda: basta localizar o valor da variável de maior frequência.

Ex: Qual a temperatura mais comum medida no mês abaixo:

Temperatura	Frequência
0° C	3
1° C	9
2° C	12
3° C	6

Resp: 2° C é a temperatura modal, pois é a de maior frequência.

b) Com intervalos de classe: A classe que apresenta a maior frequência é denominada classe modal. Pela definição, podemos afirmar que a moda, neste caso, é o valor dominante que está compreendido entre os limites da classe modal.

O método mais simples para o cálculo da moda consiste em tomar o ponto médio da classe modal. Damos a esse valor a denominação de moda bruta: $M_o = (l_i + l_s)/2$, onde l_i = limite inferior da classe modal e l_s = limite superior da classe modal.

Exemplo: Calcule a altura modal conforme a tabela abaixo.

Altura (cm)	Nº de Pessoas
54 — 58	9
58 — 62	11
62 — 66	8
66 — 70	5

Resposta: a classe modal é 58|— 62, pois é a de maior frequência. $l_i = 58$ e $l_s = 62$

$M_o = (58+62) / 2 = 60$ cm (este valor é estimado, pois não conhecemos o valor real da moda).

Método mais elaborado pela fórmula de CZUBER:

$$M_o = l_i + \left[\frac{f_{M_o} - f_{ant}}{2 \times f_{M_o} - (f_{ant} + f_{post})} \right] \times h \quad \text{ou} \quad M_o = l_i + \left[\frac{f_{M_o} - f_{ant}}{2 \times f_{M_o} - f_{ant} - f_{post}} \right] \times h$$

onde: l_i = Limite inferior da classe modal (a classe de maior frequência);

f_{M_o} = Frequência da classe modal;

f_{ant} = Frequência simples anterior à classe modal;

f_{post} = Frequência simples posterior à classe modal;


h = Intervalo de classe.

Ex.: Calcule a Moda, da tabela do exemplo anterior, pelo processo de CZUBER

$$M_o = l_i + \left[\frac{f_{M_o} - f_{ant}}{2 \times f_{M_o} - (f_{ant} + f_{post})} \right] \times h = 58 + \left[\frac{11 - 9}{2 \times 11 - (9 + 8)} \right] \times 4 = 59,6$$

Obs.: A moda é utilizada quando desejamos obter uma medida rápida e aproximada de posição ou quando a medida de posição deva ser o valor mais típico da distribuição. Já a média aritmética é a medida de posição que possui a maior estabilidade e a mediana é a medida mais central.

Para distribuições *simétricas*, a média, mediana e moda são aproximadamente iguais.
Para *assimétricas*, temos a seguinte configuração:



A relação entre média ($\bar{X}$) e mediana (M_d) para as amostras a seguir é:

- i) Distribuição Simétrica: $\bar{X} = M_d$
- ii) Distribuição Assimétrica à direita: $\bar{X} > M_d$
- iii) Distribuição Assimétrica à esquerda: $\bar{X} < M_d$

B) MEDIDAS SEPARATRIZES (OU MEDIDAS DE POSIÇÃO)

Além das medidas de posição que estudamos, há outras que, consideradas individualmente, não são medidas de tendência central, mas estão ligadas à mediana relativamente à sua característica de separar a série em partes que apresentam o mesmo número de valores.

Essas medidas - os quartis, os decis e os percentis - são conhecidas pelo nome genérico de separatrizes.

B.1) QUARTIS (Q_q): Denominamos quartis os valores de uma série que a dividem em quatro partes iguais. Precisamos, portanto, de 3 quartis (Q_1 , Q_2 e Q_3) para dividir a série em quatro partes iguais.

Obs: O quartil 2 (Q_2) SEMPRE SERÁ IGUAL A MEDIANA DA SÉRIE.

i) QUARTIS EM DADOS NÃO AGRUPADOS

O método mais prático é utilizar o princípio do cálculo da mediana para os 3 quartis. Na realidade serão calculadas “3 medianas” em uma mesma série.

Exemplo 1: Calcule os quartis da série: {5, 2, 6, 9, 10, 13, 15}

- O primeiro passo a ser dado é o da ordenação (crescente ou decrescente) dos valores:
{2, 5, 6, 9, 10, 13, 15}

- O valor que divide a série em duas partes iguais é igual a 9, logo: $M_d = 9 = Q_2$
- Temos {2, 5, 6} e {10, 13, 15} como sendo os dois grupos de valores iguais proporcionados pela mediana (quartil 2). Para o cálculo do quartil 1 e 3 basta calcular as medianas das partes iguais provenientes da verdadeira Mediana da série (quartil 2).
Logo em {2, 5, 6} a mediana é = 5. Ou seja: será o Quartil 2 = $Q_2 = 5$
Em {10, 13, 15} a mediana é = 13. Ou seja: será o Quartil 2 = $Q_2 = 13$

Exemplo 2: Calcule os quartis da série: {1, 1, 2, 3, 5, 5, 6, 7, 9, 9, 10, 13}

A série já está ordenada, então calcularemos o Quartil 2 = $M_d = (5+6)/2 = 5,5$

O quartil 1 será a mediana da série à esquerda de M_d : {1, 1, 2, 3, 5, 5}

$$Q_1 = (2+3)/2 = 2,5$$

O quartil 3 será a mediana da série à direita de M_d : {6, 7, 9, 9, 10, 13}

$$Q_3 = (9+9)/2 = 9$$

ii) QUARTIS PARA DADOS AGRUPADOS EM TABELAS

a) Sem intervalos de classe: Uma vez agrupados os dados, é possível determinar o quartil q (Q_q) pela frequência acumulada.

1º passo: calcula-se a posição: $(q \times \sum f_i)/4 = (q \times n)/4$;

2º passo: identifica-se o valor Q_q pela frequência acumulada.

b) Com intervalos de classe: A fórmula para determinação dos quartis para dados agrupados é semelhante à usada para o cálculo da mediana.

Passos para determinação do Quartil (Q_q):

1º passo: calcula-se a posição: $(q \times \sum f_i)/4 = (q \times n)/4$;

2º passo: identifica-se a classe onde se encontra o elemento Q_q pela coluna das frequências acumuladas;

3º passo: Aplica-se a fórmula:

$$Q_q = l + \left[\frac{\frac{\sum f_i}{4} \times q - F_{Ac(ant)}}{f} \right] \times h = l + \left[\frac{\frac{n}{4} \times q - F_{Ac(ant)}}{f} \right] \times h, \text{ para } q = 1, 2, 3$$

onde: l = Limite inferior da classe do Quartil;

$F_{Ac(ant)}$ = Frequência acumulada anterior a classe do Quartil;

f = Frequência simples da classe do Quartil;

h = Intervalo de classe.

Ex. 3 - Calcule os quartis da tabela abaixo:

Classe	Peso (kg)	Nº de pessoas (f_i)	Frequência Acumulada (F_{Ac})
1ª	50 — 54	4	4
2ª	54 — 58	9	13
3ª	58 — 62	11	24
4ª	62 — 66	8	32
5ª	66 — 70	5	37
6ª	70 — 74	3	40
	Total	40	-

O quartil 1: $(1 \times 40)/4 = 10 \Rightarrow 10^{\text{a}}$ pessoa está na 2ª classe.

Como $l = 54$, $F_{Ac(ant)} = 4$, $f = 9$, $h = 4$, substituindo esses valores na fórmula obtemos:

$$Q_1 = l + \left[\frac{\frac{n}{4} \times q - F_{Ac(ant)}}{f} \right] \times h = 54 + \left[\frac{10 - 4}{9} \right] \times 4 = 54 + \frac{6}{9} \times 4 \cong 54 + 0,6667 \times 4 = 54 + 2,6668 = 56,67$$

O quartil 2 = M_d . Temos $(2 \times 40)/4 = 20$. Logo a classe mediana (q classe que contém a 20ª pessoa) será de 58 |— 62.

Como $l = 58$, $F_{Ac(ant)} = 13$, $f = 11$, $h = 4$, substituindo esses valores na fórmula obtemos:

$$Q_2 = 58 + \left[\frac{20 - 13}{11} \right] \times 4 = 58 + \frac{7}{11} \times 4 \cong 58 + 0,6363 \times 4 = 58 + 2,5454 = 60,54$$

O quartil 3: $(3 \times 40)/4 = 30 \Rightarrow 30^{\text{a}}$ pessoa está na 4ª classe.

Como $l = 62$, $F_{Ac(ant)} = 24$, $f = 8$, $h = 4$, substituindo esses valores na fórmula obtemos:

$$Q_3 = 62 + \left[\frac{30 - 24}{8} \right] \times 4 = 62 + \frac{6}{8} \times 4 = 62 + 0,75 \times 4 = 62 + 3 = 65$$

B.2) DECIS (D_d): A definição dos decis obedece ao mesmo princípio dos quartis, com a modificação da porcentagem de valores que ficam aquém e além do decil que se pretende calcular. A fórmula básica será: $(d \times \sum f_i)/10$ onde d é o número de ordem do decil a ser calculado. Indicam-se os decis: $D_1, D_2, \dots, D_9$. Deste modo precisa-se de 9 decis para se dividir uma série em 10 partes iguais.

De especial interesse é o quinto decil, que *divide o conjunto em duas partes iguais*. Assim sendo, o QUINTO DECIL É IGUAL AO SEGUNDO QUARTIL, que por sua vez É IGUAL À MEDIANA.

Para D_5 tem-se: $(5 \times \sum f_i)/10 = \sum f_i / 2 = n/2$

Para dados agrupados em uma Tabela de distribuição de Frequências com intervalos de classe: A fórmula para determinação dos decis para dados agrupados é semelhante à usada para o cálculo da mediana e dos quartis.

Passos para Determinação do Decil (D_d):

1º passo: calcula-se a posição: $(d \times \sum f_i)/10 = (d \times n)/10$;

2º passo: identifica-se a classe onde se encontra o elemento D_d pela coluna das frequências acumuladas;

3º passo: Aplica-se a fórmula:

$$D_d = l + \left[\frac{\frac{\sum f_i \times d - F_{Ac(ant)}}{10}}{f} \right] \times h = l + \left[\frac{\frac{n \times d - F_{Ac(ant)}}{10}}{f} \right] \times h, \text{ para } d = 1, 2, \dots, 9.$$

onde: l = Limite inferior da classe do Decil;

$F_{Ac(ant)}$ = Frequência acumulada anterior a classe do Decil;

f = Frequência simples da classe do Decil;

h = Intervalo de classe.

Exemplo: Calcule o 3º decil da tabela anterior com classes.

$d = 3$ onde $(3 \times \sum f_i)/10 = (3 \times 40)/10 = 120/10 = 12$. Este resultado corresponde a 2ª classe. Portanto: $D_3 = 54 + \left[\frac{12-8}{9} \right] \times 4 = 54 + 3,55 = 57,55$.

B.3) PERCENTIL (P_p) ou CENTIL: Denomina-se percentis ou centis como sendo os noventa e nove valores que separam uma série em 100 partes iguais. Indicamos: $P_1, P_2, \dots, P_{99}$. É evidente que $P_{50} = Md$; $P_{25} = Q_1$ e $P_{75} = Q_3$.

O cálculo de um centil segue a mesma técnica do cálculo da mediana, dos quartis e dos decis, porém a fórmula será: $(p \times \sum f_i)/100$, onde p é o número de ordem do centil a ser calculado.

Para P_{45} temos: $45 \times \sum f_i / 100$

Para dados em agrupados em uma Tabela de distribuição de Frequências com intervalos de classe: A fórmula para determinação dos percentis para dados agrupados é semelhante à usada para o cálculo da mediana, dos quartis e dos decis.

Passos para Determinação do Percentil (P_p):

1º passo: calcula-se a posição: $(p \times \sum f_i)/100 = (p \times n)/100$;

2º passo: identifica-se a classe onde está o elemento P_p pela coluna das frequências acumuladas;

3º passo: Aplica-se a fórmula:

$$P_p = l + \left[\frac{\frac{\sum f_i \times p - F_{Ac(ant)}}{100}}{f} \right] \times h = l + \left[\frac{\frac{n}{100} \times p - F_{Ac(ant)}}{f} \right] \times h, \text{ para } p = 1, 2, \dots, 99.$$

onde: l = Limite inferior da classe do Percentil;


$F_{Ac(ant)}$ = Frequência acumulada anterior a classe do Percentil;

f = Frequência simples da classe do Percentil;

h = Intervalo de classe.

Relação entre as Medidas Separatrizes:

Uma relação importante entre as quatro Medidas Separatrizes é na verdade uma relação até visual, que não precisamos fazer esforço para percebê-la, basta traçar uma reta horizontal (que representará o conjunto de dados), e depois fazer as divisões, como pode ser visto a seguir:



Daí, concluí-se sem maiores dificuldades que: $Md = Q_2 = D_5 = P_{50}$

C) MEDIDAS DE DISPERSÃO

C.1) MEDIDAS DE DISPERSÃO ABSOLUTA

C.1.1) AMPLITUDE TOTAL (A_T): É a única medida de dispersão que não tem na média o ponto de referência.

i) Quando os dados não estão agrupados a amplitude total é a diferença entre o maior e o menor valor observado: $A_T = X_{Máximo} - X_{Mínimo} = X_{Máx} - X_{Mín}$

Exemplo: Para os valores 40, 45, 48, 62 e 70: $A_T = 70 - 40 = 30$.

ii) Quando os dados estão agrupados sem intervalos de classe ainda temos:

$$A_T = X_{Máx} - X_{Mín}$$

Exemplo:

X_i	f_i
0	2
1	6
3	5
4	3

$$A_T = 4 - 0 = 4$$

* Com intervalos de classe a AMPLITUDE TOTAL é a diferença entre o limite superior da última classe e o limite inferior da primeira classe. Então:

$$A_T = L_{Máx} - L_{Mín}$$

Ex.:

Classes	f_i
4 — 6	6
6 — 8	2
8 — 10	3

$$A_T = 10 - 4 = 6$$

A amplitude total tem o inconveniente de só levar em conta os dois valores extremos da série, descuidando do conjunto de valores intermediários. Faz-se uso da amplitude total quando se quer determinar a amplitude da temperatura em um dia, no controle de qualidade ou como uma medida de cálculo rápido sem muita exatidão.

C.1.2) DESVIO QUARTIL (D_q): Também chamado de amplitude semi-interquartil (ou desvio interquartil) é baseada nos quartis: $D_q = (Q_3 - Q_1)/2$

Obs: 1 - O desvio quartil apresenta como vantagem o fato de ser uma medida fácil de calcular e de interpretar. Além do mais, não é afetado pelos valores extremos, grandes ou pequenos, sendo recomendado, por conseguinte, quando entre os dados figurem valores extremos que não se consideram representativos.

2 - O desvio quartil deverá ser usado preferencialmente quando a medida de tendência central for a mediana.

3 - Trata-se de uma medida insensível à distribuição dos itens menores que Q_1 , entre Q_1 e Q_3 e maiores que Q_3 .

Ex.: Para os valores: 40, 45, 48, 62 e 70 o desvio quartil será:

$$Q_1 = (45+40)/2 = 42,5 \quad Q_3 = (70+62)/2 = 66 \quad D_q = (66 - 42,5) / 2 = \mathbf{11,75}$$

C.1.3) DESVIO MÉDIO ABSOLUTO (D_M)

Para dados brutos: É a média aritmética dos valores absolutos dos desvios tomados em relação a uma das seguintes medidas de tendência central: média ou mediana.

a) Para a Média: $D_M = \frac{\sum_{i=1}^n |X_i - \bar{X}|}{n}$

b) Para a Mediana: $D_M = \frac{\sum_{i=1}^n |X_i - M_d|}{n}$

As barras verticais indicam que são tomados os valores absolutos, prescindindo do sinal dos desvios.

Ex.: Calcular o desvio médio do conjunto de números {- 4, - 3, - 2, 3, 5}

$\bar{X} = -0,2$ e $M_d = -2$

Tabela auxiliar para cálculo do desvio médio

X_i	$X_i - \bar{X}$	$ X_i - \bar{X} $	$X_i - M_d$	$ X_i - M_d $
- 4	$(- 4) - (-0,2) = -3,8$	3,8	$(- 4) - (-2) = - 2$	2
- 3	$(- 3) - (-0,2) = -2,8$	2,8	$(- 3) - (-2) = - 1$	1
- 2	$(- 2) - (-0,2) = -1,8$	1,8	$(- 2) - (-2) = 0$	0
3	$3 - (-0,2) = 3,2$	3,2	$3 - (-2) = 5$	5
5	$5 - (-0,2) = 5,2$	5,2	$5 - (-2) = 7$	7
	$\Sigma =$	16,8	$\Sigma =$	15

Pela Média: $D_M = 16,8/5 = 3,36$

Pela Mediana: $D_M = 15/5 = 3$

C.1.4) DESVIO PADRÃO (S)

É a medida de dispersão mais geralmente empregada, pois leva em consideração a totalidade dos valores da variável em estudo. É um indicador de variabilidade bastante estável. O desvio padrão baseia-se nos desvios em torno da média aritmética e a sua fórmula básica pode ser traduzida como: a raiz quadrada da média aritmética dos

quadrados dos desvios e é representada por: $S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}}$

(para dados não-agrupados).

Ex.: Calcular o desvio padrão da população representada por {-4, -3, -2, 3, 5}.

Como $\bar{X} = -0,2$, então:

X_i	$X_i - \bar{X}$	$(X_i - \bar{X})^2$
- 4	- 3,8	14,44
- 3	- 2,8	7,84
- 2	- 1,8	3,24
3	3,2	10,24
5	5,2	27,04
	$\Sigma =$	62,8

Sabe-se que $n = 5$ e $62,8/5 = 12,56$. $S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}} = \sqrt{\frac{62,8}{5}} = \sqrt{12,56} \cong 3,54$

Obs: Quando nosso interesse não se restringe à descrição dos dados, mas partindo da amostra, visamos tirar inferências válidas para a respectiva população, convém efetuar uma modificação, que consiste em usar o divisor $n - 1$ em lugar de n . A fórmula ficará

então: $S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}}$

Se os dados $\{-4, -3, -2, 3, 5\}$ representassem uma amostra o desvio padrão amostral será a raiz quadrada de $62,8 / (5 - 1) = 3,96$.

O desvio padrão detém algumas propriedades, dentre as quais destacamos:

1ª: Somando-se (ou subtraindo-se) uma constante a todos os valores de uma variável, o desvio padrão não se altera.

2ª: Multiplicando-se (ou dividindo-se) todos os valores de uma variável por uma constante (diferente de zero), o desvio padrão fica multiplicado (ou dividido) por essa constante.

Quando os dados estão agrupados (temos a presença de frequências) a fórmula do

desvio padrão populacional será: $S = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{\sum f_i}} = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{n}}$

Para uma amostra: $S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2 \times f_i}{n-1}}$ ou $S = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{\sum f_i - 1}} = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{n-1}}$

Ex: Calcule o desvio padrão da tabela por pontos abaixo:

X_i	f_i	$X_i \times f_i$	$X_i - \bar{X}$	$(X_i - \bar{X})^2$	$(X_i - \bar{X})^2 \cdot f_i$
0	2	0	-2,1	4,41	8,82
1	6	6	-1,1	1,21	7,26
2	12	24	-0,1	0,01	0,12
3	7	21	0,9	0,81	5,67
4	3	12	1,9	3,61	10,83
Total	30	63			32,70

Sabe-se que $\sum f_i = n = 30$. Logo: $S = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{\sum f_i}} = \sqrt{\frac{32,70}{30}} = \sqrt{1,09} = 1,044$

Se considerar os dados como sendo de uma amostra o desvio padrão será:

$S = \sqrt{\frac{\sum (X_i - \bar{X})^2 \times f_i}{\sum f_i - 1}} = \sqrt{\frac{32,70}{30-1}} \cong \sqrt{1,128} = 1,062$.

O desvio padrão pode ser calculado usando a seguinte fórmula prática:

Para população

$$S = \sqrt{\frac{\sum_{i=1}^n X_i^2 \times f_i - \frac{(\sum X_i \times f_i)^2}{n}}{n}}$$

Para uma amostra

$$S = \sqrt{\frac{\sum_{i=1}^n X_i^2 \times f_i - \frac{(\sum X_i \times f_i)^2}{n}}{n-1}}$$

Ex: Calcule o desvio padrão do exemplo anterior:

X_i	f_i	$X_i \cdot f_i$	$(X_i)^2$	$(X_i)^2 \cdot f_i$
0	2	0	0	0
1	6	6	1	6
2	12	24	4	48
3	7	21	9	63
4	3	12	16	48
Total	30	63		165

Para uma população o Desvio padrão será: $DP(X) = S = \sqrt{\frac{165 - \frac{(63)^2}{30}}{30}} = \sqrt{1,09} = 1,044$.

Para uma amostra: $DP(X) = S = \sqrt{\frac{165 - \frac{(63)^2}{30-1}}{30-1}} = \sqrt{1,128} = 1,062$.

Obs.: Nas tabelas de distribuições de frequências com intervalos de classe a fórmula a ser utilizada é a mesma, sendo X_i o ponto médio do intervalo i .

Por exemplo:

Peso (Kg)	Nº de Pessoas (f_i)	X_i	$X_i \times f_i$	$X_i - \bar{X}$	$(X_i - \bar{X})^2$	$(X_i - \bar{X})^2 \times f_i$
50 — 54	4	52	208	-9	81	324
54 — 58	9	56	504	-5	25	225
58 — 62	11	60	660	-1	1	11
62 — 66	8	64	512	3	9	72
66 — 70	5	68	340	7	49	245
70 — 74	3	72	216	11	121	363
Total	40	-	2440	-	-	1240

$$\text{Média: } \bar{X} = \frac{X_1 \cdot f_1 + X_2 \cdot f_2 + \dots + X_k \cdot f_k}{n} = \frac{\sum X_i \cdot f_i}{n} = \frac{2440}{40} = 61$$

$$\text{Desvio padrão: } DP(X) = S = \sqrt{\frac{1240}{40}} = \sqrt{31} \cong 5,5678$$

C.2) VARIÂNCIA (S^2): É o desvio padrão elevado ao quadrado. A variância é uma medida que tem pouca utilidade como estatística descritiva, porém é extremamente importante na inferência estatística e em combinações de amostras.

C.3) COEFICIENTE DE VARIAÇÃO

É uma medida adimensional, útil para comparar variabilidades de diferentes amostras, onde as médias são muito desiguais ou as unidades de medidas são diferentes. O coeficiente de variação (CV) é o desvio padrão expresso em porcentagem da média, isto é, magnitude relativa do desvio padrão quando comparado com a média da distribuição das medidas; caracteriza a dispersão dos dados em termos relativos a seu valor médio. O coeficiente é dado por:

$$CV(X) = \frac{\text{Desvio Padrão}}{\text{Média}} \times 100 = \frac{S}{\bar{X}} \times 100$$

Ex.: Considere os resultados das estaturas e dos pesos de um mesmo grupo de indivíduos:

Discriminação	Média	Desvio Padrão
ESTATURAS	175 cm	5,0 cm
PESOS	68 kg	2,0 kg

Qual medida (Estatura ou Peso) possui maior homogeneidade?

Resposta: Teremos que calcular o CV da Estatura e o CV do Peso. O resultado menor será o de maior homogeneidade (menor dispersão ou variabilidade).

$CV(\text{estatura}) = (5 / 175) \times 100 = 2,85\%$ e $CV(\text{peso}) = (2 / 68) \times 100 = 2,94\%$.

Logo, nesse grupo de indivíduos, as estaturas apresentam menor grau de dispersão.

D) CORRELAÇÃO E REGRESSÃO LINEAR SIMPLES

D.1) Coeficiente de Correlação de Pearson

Frequentemente procura-se verificar se existe relação entre duas ou mais variáveis.


- O peso pode estar relacionado com a altura das pessoas;
- O consumo das famílias pode estar relacionado com sua renda,
- A demanda de um determinado produto e seu preço.

A verificação da existência e do grau de relação entre variáveis é o objeto de estudo da análise de correlação.

Se um sistema de coordenadas retangulares mostra a localização dos pontos (x, y) e se todos os pontos desse diagrama parecem cair nas proximidades de uma reta, a correlação é denominada linear.

D.1.1) Diagramas de Dispersão

Figura 16: Exemplos de Diagramas de Dispersão.



Obs.: Para correlações na forma da Figura 16(h) é necessária que seja aplicada uma transformação nos dados, ou seja, é necessário linearizar os dados, já que os mesmos não têm comportamento linear.

Sendo X a variável independente, se Y tende a aumentar quando X cresce, a correlação é denominada positiva. Se Y tende a diminuir quando X aumenta, a correlação é denominada negativa.

D.1.2) Coeficiente de Correlação de Pearson

O instrumento de medida da correlação linear é dado pelo coeficiente de correlação de Pearson. E pode ser calculado a partir da fórmula a seguir:

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad \text{ou} \quad r_{XY} = \frac{n \sum_{i=1}^n X_i Y_i - (\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{\sqrt{[n \sum_{i=1}^n X_i^2 - (\sum_{i=1}^n X_i)^2][n \sum_{i=1}^n Y_i^2 - (\sum_{i=1}^n Y_i)^2]}}$$

$$\text{Ou: } r_{XY} = \frac{\sum x_i \times y_i - \frac{\sum x_i \times \sum y_i}{n}}{\sqrt{\left[\sum x_i^2 - \frac{(\sum x_i)^2}{n} \right] \times \left[\sum y_i^2 - \frac{(\sum y_i)^2}{n} \right]}} \quad \text{ou} \quad r_{XY} = \frac{n \sum x_i \times y_i - \sum x_i \times \sum y_i}{\sqrt{[n \sum x_i^2 - (\sum x_i)^2] \times [n \sum y_i^2 - (\sum y_i)^2]}}$$

Também podemos calcular como:

$$r_{XY} = \frac{n \sum x_i \times y_i - \sum x_i \times \sum y_i}{\sqrt{[n \sum x_i^2 - (\sum x_i)^2] \times [n \sum y_i^2 - (\sum y_i)^2]}} = \frac{n(\sum x_i \times y_i) - (\sum x_i) \times (\sum y_i)}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \times \sqrt{n \sum y_i^2 - (\sum y_i)^2}}$$


Ou:

$$r_{XY} = \frac{S_{XY}}{S_X \times S_Y} = \frac{Cov(X, Y)}{DP(X) \times DP(Y)}$$

onde $Cov(X, Y) = S_{XY} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n}$; $DP(X) = S_X = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$ e $DP(Y) = S_Y = \sqrt{\frac{\sum (y_i - \bar{y})^2}{n}}$

Interpretando o valor de r ($-1 \leq r \leq 1$).

Figura 17 - Escala de Correlação entre as Variáveis X e Y.




- i) Valores de r acima de 0,90 ou abaixo de -0,90 indicam uma forte correlação;
- ii) Valores de r que vão de 0,50 a 0,90 ou de -0,50 a -0,90 indicam correlação moderada;
- iii) Valores de r de 0 a 0,50 e de -0,50 a 0,00 indicam fraca correlação.
- iv) Quanto mais próximo de -1 ou +1, mais forte será a correlação entre as variáveis.

Ex.: Construa o diagrama de dispersão e calcule o coeficiente de correlação linear entre as variáveis X e Y da tabela abaixo.

X	1	3	4	6	8	9	11	14
Y	1	2	4	4	5	7	8	9

Solução:




X	Y	XY	X ²	Y ²
1	1	1	1	1
3	2	6	9	4
4	4	16	16	16
6	4	24	36	16
8	5	40	64	25
9	7	63	81	49
11	8	88	121	64
14	9	126	196	81
56	40	364	524	256

Portanto: $r_{XY} = \frac{n \sum x_i \times y_i - \sum x_i \times \sum y_i}{\sqrt{[n \sum x_i^2 - (\sum x_i)^2] \times [n \sum y_i^2 - (\sum y_i)^2]}} = \frac{8 \times 364 - (56)(40)}{\sqrt{[8 \times 524 - (56)^2][8 \times 256 - (40)^2]}}$

$$r_{XY} = \frac{2912 - 2240}{\sqrt{[4192 - 3136][2048 - 1600]}} = \frac{672}{\sqrt{1056 \times 448}} = \frac{672}{\sqrt{473088}} = \frac{672}{687,81} \cong 0,9770$$

Ex.: X é o tempo de estudo (em horas) e Y é a nota da avaliação. A Tabela abaixo apresenta os pares de observações (X_i, Y_i) para cada estudante.

Tempo (X)	Nota (Y)
3,0	4,5
7,0	6,5
2,0	3,7
1,5	4,0
12,0	9,3




O coeficiente de correlação de Pearson é: $r_{XY} = 0,996$. Pode-se dizer que existe uma forte correlação positiva entre a nota na avaliação e o tempo de estudo; isto é, quanto maior o tempo de estudo, maior a nota na avaliação.

D.2) Análise de Regressão Linear Simples

Na prática, constata-se frequentemente a existência de uma relação entre duas (ou mais) variáveis e se deseja expressar tal relação sob forma matemática, estabelecendo-se uma equação (função) entre as variáveis. O objetivo é determinar o modelo que expressa esta relação (equação de regressão), a qual é ajustada aos dados.

Supondo a variável X independente (variável explicativa) e a variável Y aleatória (variável dependente ou resposta), dizemos que $Y = f(x)$.

As retas de regressão linear são funções resultantes do ajuste de uma função linear entre duas variáveis Y e X . Para obter a reta de regressão é necessário calcular o coeficiente angular (coeficiente de regressão) e o intercepto da reta com a ordenada Y , ou seja, o ponto onde a reta ajustada corta o eixo Y .



D.2.1) Ajustamento da Reta

Estabelecida a função $Y = a + bX$, é necessário conhecer os valores de **a** e de **b** de forma que a reta passe tão próxima quando possível dos pontos assinalados no diagrama de dispersão. Isto é, deseja-se minimizar a discrepância total entre os pontos marcados e a reta que será determinada.

Utilizando o método dos mínimos quadrados, para se estimar os parâmetros de **a** e **b**, tem-se: $b = \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n \sum X_i^2 - (\sum X_i)^2} = \frac{Cov(X,Y)}{Var(X)}$ e $a = \bar{Y} - b\bar{X}$

onde n é o número de observações ou tamanho da amostra, $\bar{X}$ é a média da variável X e $\bar{Y}$ é a média da variável Y .


A reta ajustada é representada por $\hat{Y} = Y_{est} = E(Y) = a + bX$ para **a** e **b** estimados.

Exemplo: Considere os dados abaixo:

Quantidade (X) em unidades	10	11	12	13	14	15
Custos (Y) em R\$	100	112	119	130	139	142

a) Construa o diagrama de dispersão.

Figura 20: Diagrama de dispersão.



b) Calcule o coeficiente de correlação de Pearson.

c) Encontre a reta de regressão linear ajustada.

d) Qual é o custo para 16 unidades de X?

X	Y	XY	X ²	Y ²
10	100	1000	100	10000
11	112	1232	121	12544
12	119	1428	144	14161
13	130	1690	169	16900
14	139	1946	196	19321
15	142	2130	225	20164
75	742	9426	955	93090

b) O coeficiente de correlação de Pearson é dado por:

$$r_{XY} = \frac{n \times (\sum X_i \cdot Y_i) - (\sum X_i)(\sum Y_i)}{\sqrt{[n \times (\sum X_i^2) - (\sum X_i)^2] \times [n \times (\sum Y_i^2) - (\sum Y_i)^2]}} = \frac{6 \times 9426 - (75)(742)}{\sqrt{[(6 \times 955 - (75)^2) \times (6 \times 93090 - (742)^2)]}}$$

$$r_{XY} = \frac{906}{\sqrt{105 \times 7976}} = \frac{906}{\sqrt{105} \times \sqrt{7976}} = \frac{906}{\sqrt{837480}} = \frac{906}{915,14} \cong 0,99$$

Para ajustar uma reta de regressão linear aos dados deve-se encontrar os coeficientes de regressão a e b , também chamados de parâmetros. E os mesmos são estimados a partir de:

$$b = \frac{n \times \sum X_i \times Y_i - \sum X_i \sum Y_i}{n \times \sum X_i^2 - (\sum X_i)^2}$$

$$b = \frac{6 \times 9426 - (75)(742)}{6 \times 955 - (75)^2} = \frac{906}{5730 - 5625} = \frac{906}{105} = 8,63$$

$$\bar{X} = \frac{\sum X_i}{n} = \frac{75}{6} = 12,5 \quad \bar{Y} = \frac{\sum Y_i}{n} = \frac{742}{6} = 123,67$$

$$a = \bar{Y} - b\bar{X} = 123,67 - (8,63) \times (12,5) = 15,795 \cong 15,80$$

c) Portanto a reta ajustada é dada por: $\hat{Y}_i = 15,8 + 8,63X_i$.

d) O custo para 16 unidades de X é dado a partir da substituição do valor de $X = 16$ na equação $\hat{Y}_i = 15,8 + 8,63X_i \Rightarrow \hat{Y}_{16} = 15,8 + 8,63 \times 16 = 153,88$.

Logo, o custo para 16 unidades de X é dado por R\$153,88.

D.3) Poder Explicativo do Modelo (R^2)

Também denominado ‘coeficiente de determinação’ tem por objetivo avaliar a “qualidade” do ajuste, que fornece a proporção da variação total da variável Y explicada pela variável X através da reta ajustada. $0 \leq R^2 \leq 1$ ou $0 \leq R^2 \leq 100\%$

$$R^2 = b^2 \frac{S_{XX}}{S_{YY}} \quad \text{ou} \quad R^2 = b \frac{S_{XY}}{S_{YY}}$$

$$\text{Onde: } S_{XX} = \sum X_i^2 - \frac{(\sum X_i)^2}{n} = \text{Var}(X) ; S_{YY} = \sum Y_i^2 - \frac{(\sum Y_i)^2}{n} = \text{Var}(Y) ; \text{ e}$$

$$S_{XY} = \sum X_i \times Y_i - \frac{(\sum X_i)(\sum Y_i)}{n} = \text{Cov}(X, Y)$$

Quando $R^2 = 0$, a variação explicada de Y é zero, ou seja, a reta ajustada é paralela ao eixo da variável X . Se $R^2 = 1$, a reta ajustada explicará toda a variação de Y . Assim, quanto mais próximo da unidade estiver o valor de R^2 , melhor “a qualidade” do ajuste da função aos pontos do diagrama de dispersão e quanto mais próximo de zero pior será a “qualidade” do ajuste.

Por exemplo: se o poder explicativo for 95%, significa que 95% das variações de Y são explicadas por X através da função (modelo) escolhida para relacionar as duas variáveis e 5% são atribuídas a causas aleatórias.